

IMPLEMENTACION DEL PROCESAMIENTO DEL LENGUAJE NATURAL

Gabriel Chuchuca, Vinicio Veletanga
gchuchucuaa@est.ups.edu.ec, eveletanga@est.ups.edu.ec
Ingenier'ia en Sistemas
Universidad Polit cnica Salesiana

Abstract—Las expresiones regulares son una forma de filtrar o encontrar coincidencias de características que nosotros queramos, aplicaremos expresiones regulares para extraer informacion de paginas web segun lo requerido y asi obtendremos graficos de los datos extraidos.

El procesamiento de lenguaje natural conocido como la manera en la que las maquinas y seres humanos puedan interactuar o entenderse mediante el lenguaje natural o lenguaje de los seres humanos, pero para esto se implementa metodos computacionales complejos que sean entendidos por la maquina para la respectiva comprension de los lenguajes entre maquina y humano.

Index Terms—caracteristicas, coincidencias, computacionales, datos, expresiones, extraer, graficos, informacion, lenguaje, maquina, natural, procesamiento, regulares, web.

I. INTRODUCCI N

El presente documento presenta lo relacionado con la extraccion de informacion de paginas web y la respectiva implementacion del procesamiento del lenguaje natural con un tema especifico a resolver aplicando lo visto en las horas de clase respectivas.

II. DESARROLLO

A. Definici n

Las expresiones regulares se trata de una secuencia de caracteres que son utilizadas para buscar patrones de cadenas de caracteres.

El procesamiento del Lenguaje natural es una forma de interactuar entre maquina y humano mediante metodos computacionales.

Las herramientas que utilizamos para la extraccion respectiva seran especificadas a continuacion.

- Python 3.7.5
- Visual Studio Code
- Postgresql 11.5
- Anaconda

B. Librerias que utilizamos

Las librerias utilizadas en este proyecto son los siguientes.

1) *Psycopg2*: Es el adaptador PostgreSQL m s popular para el lenguaje de programaci n Python . En esencia, implementa completamente las especificaciones de Python DB API 2.0 . Varias extensiones permiten el acceso a muchas de las caracter sticas que ofrece PostgreSQL.

2) *Urllib*: Es un paquete que recopila varios m dulos para trabajar con URL.

- `urllib.request` es para abrir y leer URL.
- `urllib.error` es la que contiene las excepciones planteadas por `urllib.request`
- `urllib.parse` es para analizar URL.

3) *requests*: Para hacer solicitudes HTTP en Python.

4) *Beautiful Soup*: Para extraer datos de archivos HTML y XML.

5) *normalize*: Permite declarar clases y propiedades de objetos.

C. Navegadores usados para la respectiva extraccion

Las maneras de pagar al momento de hacer una compra electr nica en esta pagina es:

- `bing.com`
- `ecosia.com`
- `dogpile.com`

D. Descripci n detallada de la propuesta del procesamiento del lenguaje natural

Aqui vemos la forma en que se conecta la base.

```
import psycopg2, csv
conexion = psycopg2.connect(" host=localhost dbname=postgres user=postgres password=Guabo*1920")
if conexion is not None:
    print('conexi n Exitosa')
    cursor=conexion.cursor()
    es=[]
```

Fig. 1: Conexion

```
with open('C:/Users/vinic/Downloads/7Ciclo/Formales/comparar.csv','r', encoding='utf-8') as File:
    leer = csv.reader(File, delimiter=',')
    for row in leer:
        reser=str(row[5])
        texto = str(row[0])+str(row[1])+str(row[2])
        spacy_stopwords = spacy.lang.es.stop_words.STOP_WORDS
        division = nlp(texto)
        division_filtrado = [palabra for palabra in division if not palabra.is_stop and not palabra.is_punct]
        word_freq = Counter(division_filtrado)
        common_words = word_freq.most_common(5)
        unique_words = [word for (word, freq) in word_freq.items() if freq == 1]
        stem = []
        for token in unique_words:
            palabra = str(token)
            stem.append(palabra)
        cajaPalabra = set()
        for palabra in stem:
            cajaPalabra.add(palabra)
```

Fig. 2: Lectura y filtrado

```

textol = str(row[6])+str(row[7])
division1 = nlp(textol)
division_filtrado1 = [palabra1 for palabra1 in division1 if not palabra1.is_stop and not palabra1.is_punct]
word_freq1 = Counter(division_filtrado1)
common_words1 = word_freq1.most_common(5)
unique_words1 = [word1 for (word1, freq1) in word_freq1.items() if freq1 == 1]
stem1 = []
for token1 in unique_words1:
    palabra1 = str(token1)
    stem1.append(palabra1)

comparacion = [item for item in stem1 if item in cajaPalabra]
a = len(cajaPalabra)
b = len(comparacion)
probabilidad = (b / a) * 100
res.append(probabilidad)
try:
    datos = (str(texto), str(textol), str(probabilidad))
    sql= str("UPDATE reportes set rpt_similitud"+" "+str(probabilidad)+" WHERE rpt_url_acceso="+reser+"")
    cursor1.execute(sql)
    conexion.commit()
    print(probabilidad)
except:
    print("ERROR AL INSERTAR")

```

Fig. 3: Filtrado

```

import csv, requests, re, psycopg2, psycopg2.extras, time, urllib, urllib.request, urllib.parse, requests, time
from unicodedata import normalize
from contextlib import nullcontext
from bs4 import BeautifulSoup
from contextlib import nullcontext
import array
#Conexion de la base de datos con el usuario
conexion = psycopg2.connect(" host=localhost dbname=postgres user=postgres password=Guab0*1928")
if conexion is not None:
    print('Conexión Exitosa')
ejec=conexion.cursor();

```

Fig. 4: Conexion a BD

E. Diagrama esquemático que explique como se desarrolló la propuesta y el procesos que ejecuto.

```

import csv, requests, re, psycopg2, psycopg2.extras, time, urllib, urllib.request, urllib.parse, requests, time
from unicodedata import normalize
from contextlib import nullcontext
from bs4 import BeautifulSoup
from contextlib import nullcontext
import array
#Conexion de la base de datos con el usuario
conexion = psycopg2.connect(" host=localhost dbname=postgres user=postgres password=Guab0*1928")
if conexion is not None:
    print('Conexión Exitosa')
ejec=conexion.cursor();

```

Fig. 8: Conexion

```

import csv, requests, re, psycopg2, psycopg2.extras, time, urllib, urllib.request, urllib.parse, requests, time
from unicodedata import normalize
from contextlib import nullcontext
from bs4 import BeautifulSoup
from contextlib import nullcontext
import array
#Conexion de la base de datos con el usuario
conexion = psycopg2.connect(" host=localhost dbname=postgres user=postgres password=Guab0*1928")
if conexion is not None:
    print('Conexión Exitosa')
ejec=conexion.cursor();

```

Fig. 8: Area 60-80%

F. Resultados de análisis obtenidos por competencia, areas y subareas.

- Areas




Fig. 5: Area 20%




Fig. 6: Area 20-40%







Fig. 7: Area 40-60%



- Subarea





Fig. 9: Subarea 20%

Fig. 11: Subarea 40-60%




Fig. 12: Subarea 60-80%

G. Comparación y análisis de los resultados en base a los resultados presentados por los sitios oficiales.

- Aquí buscaremos la palabra de búsqueda



Fig. 9: Búsqueda Navegador

palabra	acceso	título
character varying (500)	character varying (10000)	
Secar las manos	https://mx.hola.com/estar-bien/20200204159590/como-a...	Dlxc3vxada Mundial del Clxc3xa1ncer...
Secar las manos	https://launion.com.ar/un-reloj-para-colgar-realizado-con-u...	Un reloj para colgar realizado con una la...
Secar las manos	https://www.el-mexicano.com.mx/estatal/plagas-y-virus-al...	Plagas y virus: algo serio
Secar las manos	https://mendozaopina.com/regionales/temporada-de-ciru...	Temporada de ciruelas mendocinas, lo ...
Secar las manos	https://www.msn.com/es-es/lifestyle/belleza/c-c3-b3mo-p...	Cómo peinar un corte bob rizado
Secar las manos	https://www.lanueva.com/nota/2020-1-29-13-56-0-recome...	Recomendaciones para el lavado de ma...
Secar las manos	https://launion.com.ar/unas-piedras-se-convierten-en-obje...	Unas piedras se convierten en objetos d...
Secar las manos	https://www.elpais.com.uy/vida-actual/pasos-seguir-corre...	Los pasos a seguir para un correcto lav...
Secar las manos	https://www.unotv.com/noticias/porta/nacional/detalle/a...	Artesano hace estas impresionantes fig...
Secar las manos	https://www.elcolombiano.com/opinion/columnistas/un-a...	UN ARMA ANTIGUA CONTRA UN VIRUS ...
Secar las manos	https://life.esperio.com/about	About Esperio and the Team

Fig. 10: Comprobación del título y url

https://www.elpais.com.uy/vida-actual/pasos-seguir-correcto-lavado-manos-asi-evitar-entermedades-infecciosas.html	Los paso
https://www.unotv.com/noticias/porta/nacional/detalle/artesano-hace-estas-impresionantes-figuras-con-desechos-de-l...	Artesano
https://www.elcolombiano.com/opinion/columnistas/un-arma-antigua-contr-un-virus-moderno-EI12382969	UN ARMA

Fig. 11: Copiamos el url




Fig. 12: Comprobación en navegador

H. Tiempos de ejecución y recursos utilizados del computador en cada consulta o PLN.

El tiempo de ejecución vario dependiendo del tipo de ejecución que se realizó para la extracción e implementación del Lenguaje. Los recursos utilizados son los softwares para programar la estructura del programa, la base de datos que será fundamental para poder comparar palabras, las librerías NLP que sirven para poder implementar los lenguajes naturales.

- NLTK: 2.5min x ejecución
- Spacy: 3.18min x ejecución

III. CONCLUSIÓN

En conclusión, la forma de implementar el procesamiento de lenguaje natural sirve mucho para la búsqueda de palabras y coincidencias, ya que ofrece una gran cantidad de herramientas para poder sacarle mucha información de una oración o páginas url.

REFERENCES

- [1] "Natural Language Toolkit — NLTK 3.4.5 documentation", Nltk.org, 2020. [Online]. Available: <https://www.nltk.org/>. [Accessed: 10- Feb- 2020].
- [2] PERKINS, NATURAL LANGUAGE PROCESSING. [Birmingham, UK]: PACKT Publishing, 2017.
- [3] Spacy.io, 2019. [Online]. Available: <https://spacy.io/api/doc>. [Accessed: 10- Feb- 2020].